

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о программном проекте на тему:
Прогнозирование сроков выполнения задач с использованием методов машинного обучения

Выполнил:

студент группы БКНАД241

Попов Артемий Дмитриевич

22.05.26

(дата)

Принял руководитель проекта:

Вирченко Даниил

Менеджер проектов

ООО «Яндекс.Доставка Холдинг»

Москва 2026

Введение	3
Глава 1. Теоретические основы прогнозирования сроков выполнения задач	4
1.1. Проблема оценки сроков выполнения задач	4
1.2. Использование машинного обучения для прогнозирования ETA	5
1.3. Методы машинного обучения, используемые в работе	6
1.4. Метрики оценки качества модели	7
Глава 2. Анализ исходных данных	8
2.1. Описание исходного датасета	8
2.2. Описание признаков исходного датасета	8
2.3. Анализ структуры данных	9
Глава 3. Предобработка данных и формирование признаков	10
3.1. Подготовка данных и создание целевой переменной	10
3.2. Обработка пропусков и создание дополнительных признаков	10
3.3. Предотвращение утечки данных	11
Глава 4. Корреляционный анализ данных	12
4.1. Цель корреляционного анализа	12
4.2. Построение корреляционной матрицы Phi_K	12
4.3. Анализ полученных взаимосвязей	13
4.4. Ограничения корреляционного анализа	13
Глава 5. Подготовка данных для обучения модели	14
5.1. Выбор признаков и целевой переменной	14
5.2. Разделение признаков по типам обработки	14
5.3. Разделение данных на обучающую и тестовую выборки	15
5.4. Создание пайплайна предобработки	15
Глава 6. Обучение моделей и подбор гиперпараметров	16
6.1. Выбор моделей для обучения	16
6.2. Метрика качества	16
6.3. Подбор гиперпараметров	17
6.4. Результаты подбора моделей	17
Глава 7. Оценка качества модели и анализ ошибок	18
7.1. Оценка качества модели на тестовой выборке	18
7.2. Сравнение с baseline-моделью	18
7.3. Медианная абсолютная ошибка	19
7.4. Анализ ошибок по группам задач	19
7.5. Ограничения полученной модели	20
Заключение	20

Введение

В современных командах разработки программного обеспечения одной из важных задач управления проектами является точное планирование сроков выполнения задач. От корректности оценки трудоемкости зависит качество планирования спринтов, соблюдение сроков поставки функциональности, распределение нагрузки между сотрудниками и надежность обещаний, которые команда дает заказчикам и бизнесу. На практике фактическое время выполнения задачи часто отличается от первоначальной оценки: одни задачи оказываются недооцененными, другие – переоцененными. Это приводит к нарушению планов, увеличению сроков реализации проектов и снижению прозрачности процесса разработки.

Актуальность темы обусловлена необходимостью повышения точности прогнозирования сроков выполнения задач на основе исторических данных. В системах управления задачами накапливается информация о типе задачи, приоритете, дате создания и завершения, тегах, оценке в story points, длине описания и других характеристиках. Эти данные могут быть использованы для построения модели машинного обучения, способной выявлять закономерности между признаками задачи и фактическим временем ее выполнения.

В рамках данной курсовой работы рассматривается задача прогнозирования ETA - фактического времени закрытия задачи. Для этого используется исторический датасет, содержащий информацию о 15344 задачах и 11 исходных признаках, включая приоритет, тип задачи, статус, дату создания, дату завершения, теги, story points, длину описания и длину названия задачи. На основе даты создания и даты завершения формируется целевой признак eta_hours, отражающий фактическое время выполнения задачи в часах.

Целью курсовой работы является разработка модели машинного обучения для прогнозирования сроков выполнения задач и анализа отклонений между планируемыми и фактическими сроками.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Проанализировать предметную область прогнозирования сроков выполнения задач.
2. Изучить структуру исходного датасета и описать его признаки.
3. Провести первичный анализ данных, выявить пропуски, дубликаты и особенности распределения целевого признака.
4. Выполнить предобработку данных: переименование колонок, обработку пропусков, удаление некорректных значений и ограничение выборки типовыми задачами.
5. Сформировать целевой признак eta_hours и логарифмированный целевой признак eta_hours_log.
6. Создать дополнительные признаки на основе даты создания задачи, тегов, story points и текстовых характеристик.
7. Провести корреляционный анализ признаков с использованием коэффициента Phi_K.
8. Подготовить данные для обучения моделей машинного обучения.

9. Обучить несколько регрессионных моделей и выполнить подбор гиперпараметров с помощью GridSearchCV.
10. Оценить качество лучшей модели в часах и днях, сравнить ее с baseline-моделью и проанализировать ошибки по группам задач.

Объектом исследования является процесс планирования и выполнения задач в системе управления задачами.

Предметом исследования являются методы машинного обучения для прогнозирования фактического времени выполнения задач на основе исторических данных.

В работе используются методы анализа и предобработки данных, корреляционный анализ Phi_K, методы кодирования категориальных признаков, регрессионные модели машинного обучения, кросс-валидация и подбор гиперпараметров. В качестве моделей рассматриваются линейная регрессия, дерево решений, случайный лес и градиентный бустинг. Качество моделей оценивается с помощью средней абсолютной ошибки MAE и медианной абсолютной ошибки.

Практическая значимость работы заключается в том, что разработанная модель может использоваться как вспомогательный инструмент при планировании задач. Она позволяет получить ориентировочный прогноз срока выполнения задачи, сравнить его с первоначальной оценкой и выявить группы задач, по которым команда чаще всего допускает значительные отклонения. При этом модель не заменяет экспертную оценку команды, а дополняет ее за счет анализа накопленных исторических данных.

Глава 1. Теоретические основы прогнозирования сроков выполнения задач

1.1. Проблема оценки сроков выполнения задач

Планирование сроков выполнения задач является одной из ключевых составляющих управления проектами в сфере разработки программного обеспечения. От качества оценки сроков зависит возможность команды планировать спринты, распределять нагрузку между исполнителями, согласовывать сроки с заказчиками и контролировать выполнение проекта. Если сроки оцениваются неточно, это может привести к срыву планов, увеличению стоимости проекта и снижению доверия со стороны бизнеса.

На практике оценка сроков выполнения задач часто оказывается неточной. Команды могут недооценивать трудоемкость задачи, если не учитывают скрытую сложность, технический долг, необходимость дополнительных согласований или зависимость от других задач. Также возможна переоценка трудоемкости, когда задача кажется более сложной, чем оказывается в действительности. В результате возникает расхождение между планируемыми и фактическими сроками выполнения.

Одной из причин подобных отклонений является то, что оценка задач часто основана на экспертном мнении участников команды. Такой подход полезен, так как учитывает опыт специалистов, однако он может быть субъективным. Разные исполнители могут по-разному оценивать одну и ту же задачу, а одинаковые по описанию задачи могут требовать разного времени в зависимости от проекта, типа задачи, приоритета, используемых технологий и других факторов.

В системах управления задачами накапливаются исторические данные, которые могут быть использованы для повышения точности планирования. К таким данным относятся тип задачи, приоритет, дата создания, дата завершения, теги, оценка в story points, длина описания и другие характеристики. В рамках рассматриваемого проекта исходный датасет включает 15 344 записи и 11 признаков. Среди них используются приоритет, тип задачи, статус, резолюция, даты создания и завершения, теги, story points, а также длина описания и названия задачи. Такой набор данных позволяет анализировать не только формальные характеристики задач, но и отдельные косвенные признаки их сложности, например объем текстового описания или наличие определенных тегов.

Использование исторических данных дает возможность дополнить экспертную оценку сроков более формализованным подходом. В проекте прогнозирование ETA рассматривается не как замена решениям команды, а как вспомогательный инструмент планирования. Модель может показать, насколько предполагаемый срок выполнения согласуется с похожими задачами из прошлого, а также помочь выявить случаи, где оценка выглядит завышенной или, наоборот, слишком оптимистичной.

1.2. Использование машинного обучения для прогнозирования ETA

ETA - это ожидаемое время выполнения или закрытия задачи. В контексте данной работы под ETA понимается фактическое время между созданием задачи и ее завершением. Для построения модели это время можно представить как числовой целевой признак, который требуется спрогнозировать на основе характеристик задачи.

Задача прогнозирования ETA относится к задачам регрессии. Регрессия используется, когда необходимо предсказать числовое значение. В данной работе необходимо предсказать количество часов, которое потребуется для выполнения задачи. Поэтому на основании даты создания и даты завершения формируется целевой признак `eta_hours`, показывающий фактическое время выполнения задачи.

Решению задачи прогнозирования включает несколько этапов. Сначала выполняется сбор и анализ исторических данных, затем проводится предобработка, после этого данные разделяются на обучающую и тестовую выборки. На обучающей выборке модель выявляет закономерности между признаками задачи и фактическим временем выполнения. На тестовой выборке проверяется, насколько хорошо модель способна прогнозировать.

Важным этапом подготовки данных является предотвращение утечки данных. Под утечкой понимается ситуация, когда в обучающую выборку попадает информация, которая в реальном сценарии прогнозирования еще не была бы известна. Для задачи оценки ETA это особенно важно, поскольку модель должна работать с новой задачей до ее

фактического завершения. Например, дату завершения нельзя использовать как входной признак, так как она становится известна только после выполнения задачи. По этой же причине нельзя включать признаки, рассчитанные на основе фактического времени выполнения, если цель модели - заранее предсказать срок.

В данной работе из обучающей выборки исключаются признаки, которые могут привести к утечке данных: дата завершения задачи, статус, резолюция, исходные значения целевой переменной, а также признаки, напрямую рассчитанные на основе фактической длительности выполнения. Статус и резолюция также исключаются, поскольку на момент постановки новой задачи они либо неизвестны, либо еще не отражают итоговый результат работы. Таким образом модель обучается только на той информации, которая действительно могла бы быть доступна до завершения задачи.

1.3. Методы машинного обучения, используемые в работе

Для прогнозирования в работе рассматриваются несколько моделей: линейная регрессия, дерево решений, случайный лес и градиентный бустинг. Такой набор позволяет сравнить как простые и хорошо интерпретируемые подходы, так и более гибкие алгоритмы, способные учитывать нелинейные зависимости в данных.

Линейная регрессия предполагает, что целевая переменная связана с признаками линейной зависимостью. Преимущество такого подхода заключается в простоте, высокой скорости обучения и относительной интерпретируемости результатов. На практике линейная регрессия может быть полезна как baseline, то есть как начальная точка сравнения для более сложных моделей. Если более сложный алгоритм показывает лишь незначительное улучшение по MAE, это может означать, что усложнение модели не дает существенной практической пользы.

Однако для задачи прогнозирования линейная регрессия может быть недостаточно гибкой. Такие зависимости не всегда хорошо описываются простой линейной формулой, поэтому в работе рассматриваются и нелинейные модели.

Дерево решений прогнозирует последовательно разбивая данные по значениям признаков. Такой подход позволяет учитывать нелинейные зависимости между признаками. Например, модель может отдельно обрабатывать задачи разных типов, а внутри них дополнительно учитывать приоритет, story points или наличие определенных тегов. За счет этого дерево решений может находить более сложные правила, чем линейная регрессия. При этом у одиночного дерева есть существенное ограничение: при большой глубине оно может слишком точно подстроиться под обучающую выборку и хуже работать на новых задачах. Поэтому при использовании такой модели важно контролировать ее сложность.

Случайный лес является ансамблевой моделью, основанной на множестве деревьев решений. Вместо одного дерева строится несколько моделей, а итоговый прогноз формируется путем усреднения их результатов. Это снижает зависимость от случайных особенностей обучающей выборки и обычно делает прогноз более устойчивым. Для табличных данных, подобных датасету задач, случайный лес подходит тем, что может

учитывать нелинейные связи между признаками и при этом менее склонен к переобучению, чем одно дерево решений.

Градиентный бустинг также относится к ансамблевым методам, но строит модели последовательно. Каждая следующая модель обучается так, чтобы уменьшить ошибки, оставшиеся после предыдущих шагов. В данной работе используется HistGradientBoostingRegressor - вариант градиентного бустинга для задачи регрессии. Его применение оправдано тем, что в данных о задачах могут присутствовать сложные зависимости. Такая модель позволяет проверить, можно ли за счет более гибкого алгоритма снизить ошибку прогнозирования ETA по сравнению с baseline.

Для подбора гиперпараметров моделей используется GridSearchCV. Этот метод перебирает заранее заданные комбинации параметров и оценивает качество модели с помощью кросс-валидации. Кросс-валидация позволяет получить более устойчивую оценку качества, поскольку модель обучается и проверяется на нескольких вариантах разделения выборки.

1.4. Метрики оценки качества модели

После обучения модели необходимо оценить качество ее прогнозов. Основной метрикой в данной работе является MAE - средняя абсолютная ошибка. MAE показывает, на сколько в среднем прогноз модели отличается от фактического значения. Она измеряется в тех же единицах, что и целевая переменная. Поэтому ее удобно интерпретировать в часах или днях.

Также используется медианная абсолютная ошибка. Эта метрика показывает типичную ошибку модели для середины выборки. Она менее чувствительна к отдельным большим ошибкам, чем MAE. Если медианная ошибка заметно меньше, большинство задач прогнозируется точнее, но отдельные сложные задачи сильно увеличивают среднюю ошибку.

Глава 2. Анализ исходных данных

2.1. Описание исходного датасета

Для решения задачи прогнозирования сроков выполнения задач используется исторический датасет, содержащий информацию о задачах из системы управления разработкой. Каждая строка датасета соответствует одной задаче, для которой зафиксированы основные характеристики: приоритет, тип, уникальный ключ, статус, резолюция, дата создания, дата завершения, теги, оценка трудоемкости в story points, длина описания и длина названия.

Исходные данные были загружены из файла с помощью библиотеки pandas. Для первичного ознакомления с данными была выведена случайная выборка из пяти строк.

Это позволило оценить структуру таблицы, формат хранения дат, значения категориальных признаков и примеры тегов, присвоенных задачам.

Первичный анализ структуры датасета был выполнен с помощью метода `df.info()`. В результате было установлено, что исходный датасет содержит 15344 записи и 11 признаков. Среди них присутствуют категориальные признаки, числовые признаки и признаки даты. Даты создания и завершения задачи представлены в формате `datetime64[ns]`, что позволяет в дальнейшем использовать их для расчета фактического времени выполнения задачи.

Таким образом, исходный датасет содержит данные, которые могут быть использованы для построения модели прогнозирования сроков выполнения задач. При этом перед обучением модели необходимо выполнить дополнительную обработку: привести названия колонок к удобному формату, обработать пропуски, сформировать целевой признак и исключить признаки, которые могут привести к утечке данных.

2.2. Описание признаков исходного датасета

Признак	Описание
Приоритет	Приоритет задачи. Отражает степень важности или срочности задачи.
Тип	Тип задачи.
Ключ	Уникальный идентификатор задачи.
Статус	Текущий или финальный статус задачи.
Резолюция	Результат завершения задачи.
Создано	Дата и время создания задачи.
Дата завершения	Дата и время закрытия задачи.
Теги	Теги задачи, описывающие направление, модуль или дополнительные характеристики.
Original Story Points	Первоначальная оценка трудоемкости задачи в story points.
Длина описания	Количество символов или длина текстового описания задачи.
Длина названия	Количество символов или длина названия задачи.

Часть признаков может быть использована при построении модели после предварительной обработки. Например, Приоритет и Тип являются категориальными признаками и требуют кодирования. Признак Original Story Points является числовым и

может отражать первоначальную оценку трудоемкости задачи. Признаки Длина описания и Длина названия могут косвенно характеризовать степень детализации задачи.

Отдельно следует отметить признаки Создано и Дата завершения. Наличие этих колонок позволяет в дальнейшем рассчитать фактическое время выполнения задачи. Однако сама дата завершения не может использоваться как входной признак модели, так как она становится известна только после выполнения задачи.

2.3. Анализ структуры данных

На этапе первичного анализа были изучены типы данных и количество непустых значений в каждом признаке. В датасете присутствуют:

- 6 признаков типа object;
- 2 признака типа datetime64[ns];
- 1 признак типа float64;
- 2 признака типа int64.

Категориальные признаки представлены колонками Приоритет, Тип, Ключ, Статус, Резолюция и Теги. Числовые признаки представлены колонками Original Story Points, Длина описания и Длина названия. Временные признаки представлены колонками Создано и Дата завершения.

Такой состав данных подходит для решения задачи регрессии, так как содержит как характеристики самой задачи, так и информацию о сроке ее фактического завершения. Однако данные требуют подготовки, поскольку модели машинного обучения не могут напрямую работать со всеми исходными признаками в текущем виде. Категориальные признаки необходимо закодировать, пропуски - обработать, а временные признаки - преобразовать в новые числовые характеристики.

Глава 3. Предобработка данных и формирование признаков

3.1. Подготовка данных и создание целевой переменной

После анализа исходного датасета был выполнен этап предобработки данных. Первым шагом названия колонок были приведены к единому техническому формату на английском языке. Это позволяет упростить дальнейшую работу с данными и сделать код более читаемым. Например, колонка Приоритет была переименована в priority, Тип - в type, Создано - в created_at, Дата завершения - в completed_at, а Original Story Points - в story_points.

Далее был создан целевой признак eta_hours, отражающий фактическое время выполнения задачи в часах. Он рассчитывается как разница между датой завершения и датой создания задачи:

```
df['eta_hours'] = (df['completed_at'] - df['created_at']).dt.total_seconds() / 3600
```

Дополнительно был создан признак `eta_days`, который переводит время выполнения из часов в дни и используется для более удобной интерпретации результатов.

После расчета целевой переменной был проведен анализ ее распределения. Было выявлено, что распределение `eta_hours` имеет длинный правый хвост: большинство задач закрывается за относительно ограниченное время, однако часть задач имеет очень большие сроки выполнения. Также были обнаружены некорректные значения, при которых фактическое время выполнения задачи оказалось отрицательным. Такие наблюдения не могут использоваться при обучении модели, так как дата завершения не должна быть меньше даты создания.

Для повышения устойчивости модели выборка была ограничена типовыми задачами со сроком выполнения до 45 дней. Более длительные задачи были исключены, поскольку они могут отражать не только реальную трудоемкость, но и организационные задержки, блокировки или несвоевременное закрытие задачи в системе. После фильтрации размер выборки составил 12237 строк.

Так как распределение целевого признака остается скошенным, для обучения модели был создан логарифмированный целевой признак `eta_hours_log`:

```
df_model['eta_hours_log'] = np.log1p(df_model['eta_hours'])
```

Логарифмирование позволяет уменьшить влияние больших значений целевой переменной на обучение модели. При оценке качества прогнозы переводятся обратно в часы с помощью обратного преобразования `np.expml`.

3.2. Обработка пропусков и создание дополнительных признаков

После формирования целевой переменной были обработаны пропущенные значения. В колонке `tags` пропуски были заменены на значение `unknown`, так как отсутствие тегов может быть самостоятельной характеристикой задачи. Для признака `story_points` сначала был создан бинарный индикатор `has_story_points`, показывающий, была ли у задачи изначально указана оценка трудоемкости. После этого пропущенные значения в `story_points` были заполнены медианой.

Далее были сформированы дополнительные признаки. Из даты создания задачи были выделены временные характеристики: год, месяц, день месяца, день недели, час создания, а также признак создания задачи в выходной день. Эти признаки позволяют учитывать возможные временные закономерности в процессе выполнения задач.

На основе тегов были созданы два типа признаков: `tags_count`, отражающий количество тегов у задачи, были выделены наиболее частые теги, и для каждого из них были созданы бинарные признаки. Такой подход позволяет модели учитывать не только количество тегов, но и принадлежность задачи к конкретным.

Также был обработан признак `story_points`, отражающий первоначальную оценку трудоемкости задачи. Помимо числового значения, был создан категориальный признак `story_points_group`, который группирует задачи по диапазонам трудоемкости. Это

позволяет модели учитывать как точное значение оценки, так и принадлежность задачи к определенной группе сложности.

Отдельно были созданы признаки `eta_per_story_point` и `planning_deviation`, которые используются только для анализа отклонений между плановыми и фактическими сроками. Они не включаются в обучающую выборку, так как рассчитываются на основе целевого признака и могут привести к утечке данных.

3.3. Предотвращение утечки данных

При подготовке данных для обучения модели важно исключить признаки, которые не будут известны в момент прогнозирования новой задачи. Если такие признаки попадут в обучающую выборку, модель может показать завышенное качество на тестовых данных, но окажется неприменимой на практике.

Из обучающей выборки были исключены дата завершения задачи, статус, резолюция, технический ключ задачи, исходная колонка с тегами, а также все признаки, напрямую связанные с целевой переменной. К таким признакам относятся `eta_hours`, `eta_hours_log`, `eta_days`, `eta_per_story_point` и `planning_deviation`.

Дата завершения задачи не может использоваться в качестве входного признака, поскольку она становится известна только после выполнения задачи. Статус и резолюция также относятся к информации, которая может быть определена уже после завершения работы. Признаки `eta_per_story_point` и `planning_deviation` рассчитываются через фактическое время выполнения, поэтому их использование при обучении привело бы к утечке целевого признака.

Таким образом, для обучения модели используются только те признаки, которые потенциально доступны на момент планирования задачи.

Глава 4. Корреляционный анализ данных

4.1. Цель корреляционного анализа

После предобработки данных и формирования новых признаков был выполнен корреляционный анализ. Его основная цель - оценить взаимосвязи между признаками и целевой переменной, а также определить, какие характеристики задачи могут быть наиболее полезны для прогнозирования срока ее выполнения.

Для анализа была использована корреляционная матрица `Phi_K`. Данный метод позволяет оценивать связи между признаками разных типов: числовыми, категориальными и смешанными.

4.2. Построение корреляционной матрицы Phi_K

Перед построением матрицы были выбраны признаки, используемые для анализа. В список вошли числовые и категориальные переменные. Числовые признаки были дополнительно переданы в параметр `interval_cols`, чтобы Phi_K корректно интерпретировал их как интервальные переменные.

Из анализа были исключены технические признаки, исходные даты и признаки, рассчитанные на основе целевой переменной. Это сделано для того, чтобы анализ отражал только те признаки, которые могут быть доступны при прогнозировании новой задачи.

После расчета матрицы была построена тепловая карта корреляций. Она позволяет визуально оценить силу взаимосвязей между признаками: чем ближе значение к 1, тем сильнее связь между двумя переменными.

4.3. Анализ полученных взаимосвязей

По результатам корреляционного анализа можно сделать вывод, что связь с целевым признаком `eta_hours_log` имеют несколько групп признаков.

Заметная связь наблюдается с временными признаками, особенно с `created_hour`. Это может говорить о том, что время создания задачи косвенно связано с особенностями рабочего процесса. Например, задачи, созданные в разное время суток, могут отличаться по характеру, срочности или способу постановки. Определенную связь показывает признак `story_points`, который отражает первоначальную оценку трудоемкости задачи. Также определенную значимость имеет признак `has_description`. Наличие описания может быть связано с уровнем детализации задачи.

Важно отметить, что бинарные признаки отдельных тегов не включались в корреляционную матрицу, чтобы не перегружать визуализацию большим количеством колонок. При этом данные признаки используются на этапе обучения модели, так как конкретные теги могут содержать важную информацию о предметной области задачи.

Глава 5. Подготовка данных для обучения модели

5.1. Выбор признаков и целевой переменной

После выполнения предобработки данных и корреляционного анализа был сформирован набор данных для обучения модели машинного обучения. В качестве целевой переменной был выбран логарифмированный признак `eta_hours_log`, который отражает фактическое время выполнения задачи в преобразованном виде. Использование логарифмированного признака позволяет снизить влияние слишком больших значений и сделать обучение модели более устойчивым.

При формировании матрицы признаков из данных были исключены колонки, которые не должны использоваться при прогнозировании новых задач. К таким признакам относятся дата завершения задачи, статус, резолюция, технический ключ задачи, исходная колонка с тегами, а также признаки, рассчитанные на основе целевой переменной. В частности, из обучающей выборки были удалены `completed_at`, `status`, `resolution`, `key`, `eta_hours`, `eta_days`, `eta_hours_log`, `eta_per_story_point` и `planning_deviation`.

Исключение этих признаков необходимо для предотвращения утечки данных. Например, дата завершения задачи становится известна только после ее выполнения, поэтому она не может использоваться для прогнозирования срока новой задачи. Аналогично признаки `eta_per_story_point` и `planning_deviation` рассчитываются на основе фактического времени выполнения, следовательно, их использование привело бы к завышенной оценке качества модели.

В результате была сформирована матрица признаков X и целевая переменная y . После добавления признаков по наиболее частым тегам итоговая матрица признаков содержала 35 колонок, а количество наблюдений составило 12237 строк.

5.2. Разделение признаков по типам обработки

Для корректной подготовки данных признаки были разделены на три группы: номинальные категориальные признаки, порядковые категориальные признаки и числовые признаки.

К номинальным категориальным признакам были отнесены `type` и `story_points_group`. Эти признаки не имеют естественного порядка, поэтому для них используется One-Hot Encoding. Такой способ кодирования создает отдельные бинарные признаки для категорий и позволяет модели корректно работать с категориальными значениями.

К порядковым категориальным признакам был отнесен `priority`. Приоритет задачи имеет естественный порядок: низкий, средний, высокий и т.д. Поэтому для него используется Ordinal Encoding. Перед кодированием значения приоритета приводятся к единому виду, чтобы модель могла корректно интерпретировать порядок категорий.

К числовым признакам были отнесены `story_points`, длина описания, длина названия, временные признаки, количество тегов, индикаторы наличия описания и `story points`, а также бинарные признаки наиболее частых тегов. Эти признаки передаются в числовой блок пайплайна и могут масштабироваться с помощью `MinMaxScaler` или `StandardScaler`.

Такое разделение признаков позволяет использовать разные способы обработки для разных типов данных и избежать некорректной интерпретации категориальных признаков.

5.3. Разделение данных на обучающую и тестовую выборки

После формирования признаков данные были разделены на обучающую и тестовую выборки. Обучающая выборка используется для настройки моделей и подбора гиперпараметров, а тестовая выборка - для итоговой проверки качества на данных,

которые модель не видела во время обучения. В работе использовалось разбиение в соотношении 80% на обучение и 20% на тестирование.

При этом стоит отметить, что в дальнейшем для более реалистичной проверки качества можно использовать временное разбиение: обучать модель на более ранних задачах и тестировать на более поздних. Такой способ ближе к реальному применению модели, когда прогноз строится для будущих задач.

5.4. Создание пайплайна предобработки

Для автоматизации обработки признаков был создан общий пайплайн предобработки. Он объединяет обработку категориальных и числовых признаков в единую структуру.

Для номинальных категориальных признаков используется пайплайн с заполнением пропусков наиболее частым значением и последующим One-Hot Encoding. Для порядкового признака `priority` применяется отдельный пайплайн: сначала значения приводятся к единому виду, затем пропуски заполняются наиболее частым значением, после чего выполняется Ordinal Encoding.

Числовые признаки обрабатываются отдельно. В рамках подбора гиперпараметров для числового блока проверяются разные варианты обработки: `MinMaxScaler`, `StandardScaler` или передача признаков без масштабирования. Это позволяет подобрать наиболее подходящий вариант обработки для конкретной модели.

Все этапы объединяются с помощью `ColumnTransformer`, который применяет разные преобразования к разным группам признаков. Далее данный предобработчик включается в общий `Pipeline` вместе с моделью машинного обучения.

Использование пайплайна имеет важное преимущество: все преобразования выполняются внутри процедуры обучения и кросс-валидации. Это снижает риск некорректной оценки качества и делает процесс обучения более воспроизводимым.

Глава 6. Обучение моделей и подбор гиперпараметров

6.1. Выбор моделей для обучения

После подготовки данных был выполнен этап обучения моделей машинного обучения. Поскольку задача заключается в прогнозировании числового значения - фактического времени выполнения задачи, она относится к задачам регрессии.

Для сравнения были выбраны несколько моделей разной сложности:

- `LinearRegression`;
- `DecisionTreeRegressor`;
- `RandomForestRegressor`;
- `HistGradientBoostingRegressor`.

Линейная регрессия использовалась как простая базовая модель. Она позволяет проверить, насколько хорошо целевая переменная может быть описана линейной зависимостью от признаков. Однако в задаче прогнозирования сроков выполнения задач зависимости между признаками могут быть сложными и нелинейными, поэтому дополнительно были рассмотрены модели на основе деревьев решений.

Дерево решений способно учитывать нелинейные зависимости, но может быть склонно к переобучению. Случайный лес решает эту проблему за счет построения ансамбля деревьев и усреднения их прогнозов. Также была рассмотрена модель градиентного бустинга `HistGradientBoostingRegressor`, которая последовательно строит несколько моделей и исправляет ошибки предыдущих.

6.2. Метрика качества

В качестве основной метрики качества была выбрана средняя абсолютная ошибка - MAE. Данная метрика показывает, насколько в среднем прогноз модели отличается от фактического значения.

Так как модель обучается на логарифмированном целевом признаке `eta_hours_log`, значение метрики на этапе кросс-валидации также рассчитывается в логарифмическом масштабе. Поэтому результат `mean_test_score`, полученный при подборе гиперпараметров, нельзя напрямую интерпретировать как ошибку в часах.

Для практической оценки качества после получения прогноза выполняется обратное преобразование:

```
y_pred_hours = np.exp1(y_pred_log)
```

После этого ошибка рассчитывается уже в исходных единицах измерения - часах и днях. Такой подход позволяет совместить устойчивость обучения на логарифмированной целевой переменной и удобную бизнес-интерпретацию результата.

6.3. Подбор гиперпараметров

Для выбора лучшей модели и оптимальных параметров был использован `GridSearchCV`. Данный метод перебирает заданные комбинации гиперпараметров и оценивает качество моделей с помощью кросс-валидации.

В рамках подбора гиперпараметров сравнивались разные модели и варианты их настройки. Для дерева решений подбирались максимальная глубина дерева, минимальное количество объектов для разделения узла и минимальное количество объектов в листе. Для случайного леса дополнительно подбиралось количество деревьев. Для градиентного бустинга подбирались количество итераций, скорость обучения, количество листьев и коэффициент регуляризации.

Также в процессе подбора проверялись разные способы обработки числовых признаков: масштабирование с помощью `MinMaxScaler`, `StandardScaler` или передача

числовых признаков без масштабирования. Это позволило выбрать не только модель, но и наиболее подходящий вариант предобработки данных.

Использование GridSearchCV внутри общего Pipeline важно, потому что все этапы предобработки выполняются корректно внутри кросс-валидации. Это снижает риск некорректной оценки качества модели.

6.4. Результаты подбора моделей

По результатам подбора гиперпараметров лучшей моделью оказался HistGradientBoostingRegressor. В таблице лучших результатов первые позиции заняли именно варианты данной модели с разными значениями гиперпараметров.

Лучшая модель имела следующие основные параметры:

```
HistGradientBoostingRegressor(  
    l2_regularization=0.1,  
    learning_rate=0.05,  
    max_iter=200,  
    max_leaf_nodes=63,  
    random_state=42  
)
```

Лучшее значение метрики на кросс-валидации составило примерно 0.7923. Данное значение рассчитано в логарифмическом масштабе, так как целевой переменной при обучении является eta_hours_log.

Полученный результат показывает, что градиентный бустинг лучше справился с задачей, чем более простые модели. Это можно объяснить тем, что срок выполнения задачи зависит не от одного признака, а от сложной комбинации факторов: типа задачи, приоритета, story points, тегов, временных признаков и характеристик описания.

Глава 7. Оценка качества модели и анализ ошибок

7.1. Оценка качества модели на тестовой выборке

После подбора гиперпараметров лучшая модель была проверена на тестовой выборке. На этапе обучения целевой признак был представлен в логарифмированном виде eta_hours_log, поэтому перед расчетом итоговых метрик прогнозы были преобразованы обратно в часы с помощью функции `np.expml`.

Такой подход позволяет оценивать качество модели в исходных единицах измерения, то есть в часах и днях. Это важно, поскольку результат модели должен быть понятен с точки зрения практического планирования задач.

По итогам проверки на тестовой выборке значение средней абсолютной ошибки составило:

MAE = 169.25 часов

В пересчете на дни это составляет:

MAE = 7.05 дня

Таким образом, модель в среднем ошибается примерно на 7 дней при прогнозировании срока выполнения задачи. Данное значение нельзя считать полностью незначительным, однако оно показывает, что модель способна давать более точный прогноз по сравнению с простым базовым подходом.

7.2. Сравнение с baseline-моделью

Для оценки практической полезности модели было выполнено сравнение с baseline-моделью. В качестве baseline использовалась простая модель, которая для всех задач предсказывает медианное значение срока выполнения.

Такое сравнение необходимо, потому что само по себе значение MAE не показывает, насколько модель лучше простого правила. Если ML-модель не превосходит baseline, ее применение не имеет практического смысла.

В результате baseline-модель показала ошибку:

Baseline MAE = 210.25 часов

Итоговая ML-модель показала ошибку:

Model MAE = 169.25 часов

Улучшение относительно baseline составило примерно:

19.5%

Это означает, что обученная модель действительно выявляет полезные закономерности в данных и позволяет снизить среднюю ошибку прогноза по сравнению с простым медианным предсказанием.

7.3. Медианная абсолютная ошибка

Помимо средней абсолютной ошибки была рассчитана медианная абсолютная ошибка. Она показывает типичную ошибку модели для середины выборки и менее чувствительна к отдельным большим ошибкам.

В результате было получено:

Median AE = 104.90 часов

В пересчете на дни:

Median AE = 4.37 дня

Медианная ошибка заметно ниже средней абсолютной ошибки. Это говорит о том, что для значительной части задач модель прогнозирует срок точнее, чем показывает среднее значение MAE. Однако отдельные сложные задачи дают большие ошибки и увеличивают среднюю ошибку модели.

Таким образом, можно сделать вывод, что модель лучше работает на типовых задачах, но хуже справляется с задачами, которые имеют нестандартные характеристики или редко встречаются в данных.

7.4. Анализ ошибок по группам задач

Для более детального понимания качества модели был проведен анализ ошибок по отдельным группам признаков: типу задачи, приоритету и значению story points.

Анализ по типу задачи показал, что наибольшая средняя ошибка наблюдается у задач типа “Задача”. Для Technical Task и “Ошибка” средняя ошибка ниже. Это может говорить о том, что задачи общего типа более разнообразны по содержанию и срокам выполнения, поэтому их сложнее прогнозировать.

Анализ по приоритетам показал, что наибольшая ошибка наблюдается у задач с критичным приоритетом. Это может быть связано с тем, что такие задачи часто имеют нестандартный характер, требуют срочного вмешательства или зависят от дополнительных факторов, которые не представлены в текущем датасете.

Также был проведен анализ ошибок по значениям story_points. Для корректной интерпретации учитывались только группы, содержащие не менее 20 наблюдений. Наибольшие ошибки наблюдаются у задач с высокими значениями story points, например 8, 5 и 3. Это ожидаемо, так как более трудоемкие задачи обычно сложнее прогнозировать: они могут включать больше неопределенности, зависимостей и скрытых работ.

При этом задачи с малыми значениями story points прогнозируются точнее. Это видно по меньшим значениям средней и медианной ошибки для небольших оценок трудоемкости.

7.5. Ограничения полученной модели

Несмотря на улучшение качества по сравнению с baseline, итоговая ошибка модели остается достаточно заметной. Средняя абсолютная ошибка около 7 дней показывает, что прогноз нельзя рассматривать как точное значение будущего срока выполнения задачи. В контексте прогнозирования ETA такая модель скорее подходит для предварительной

проверки оценки, чем для автоматического принятия решений. Например, если прогноз сильно отличается от экспертной оценки команды, это может быть поводом дополнительно пересмотреть задачу, уточнить требования или проверить, не недооценены ли риски.

Поэтому результаты модели целесообразно использовать как вспомогательный инструмент планирования. Она может помочь команде оценить реалистичность сроков, сравнить новую задачу с исторически похожими случаями и выделить задачи, для которых существует повышенная неопределенность. Однако окончательная оценка сроков должна учитывать контекст, который не всегда представлен в датасете: срочность, приоритеты бизнеса, занятость исполнителей и организационные ограничения.

Основное ограничение модели связано с составом исходных данных. В датасете отсутствуют некоторые признаки, которые могут существенно влиять на фактический срок выполнения задачи. Например, не учитываются исполнитель, команда, проект, спринт, количество комментариев, число изменений статуса, блокировки, переоткрытия задачи и зависимости от других задач. Без этих данных модель может находить только общие закономерности между признаками и сроком выполнения, но не всегда способна объяснить, почему конкретная задача была закрыта быстрее или медленнее ожидаемого.

Это ограничение важно учитывать и при интерпретации качества модели. Даже если алгоритм, например HistGradientBoostingRegressor, показывает улучшение по MAE относительно baseline, это не означает, что он полностью описывает процесс выполнения задач. Скорее, модель использует доступные признаки - тип задачи, story_points, теги, временные характеристики и другие параметры - чтобы приблизительно восстановить зависимость между описанием задачи и ее длительностью. Если значимые факторы не попали в датасет, ошибка прогноза будет сохраняться даже при использовании более сложного алгоритма.

Отдельного внимания требуют признаки на основе тегов. Их можно использовать только в том случае, если теги известны на момент постановки или планирования задачи. Если часть тегов добавляется уже после начала работы, после уточнения требований или после завершения задачи, такие признаки могут привести к утечке данных. В этом случае модель фактически получает информацию из будущего, а значение MAE на тестовой выборке может оказаться лучше, чем при реальном применении. Поэтому при внедрении модели необходимо отдельно контролировать, какие данные действительно доступны в момент прогнозирования ETA.

Заключение

В ходе работы была достигнута основная цель проекта: разработана модель машинного обучения для прогнозирования сроков выполнения задач на основе исторических данных. Модель позволяет рассчитывать ожидаемое время выполнения задачи, то есть ETA, и использовать этот прогноз как дополнительный ориентир при планировании. При этом результат модели не рассматривается как окончательная оценка

срока, поскольку фактическая длительность задачи зависит не только от признаков, представленных в датасете, но и от контекста работы команды.

Наилучший результат среди рассмотренных моделей показал HistGradientBoostingRegressor. После обратного преобразования прогноза из логарифмического масштаба средняя абсолютная ошибка составила 169,25 часа, или около 7,05 дня. По сравнению с baseline-моделью, которая предсказывает медианное значение срока выполнения, ошибка снизилась примерно на 19,5%. Это показывает, что модель действительно находит в данных полезные закономерности и дает более точный прогноз, чем простое базовое правило. Однако само значение ошибки остается существенным, поэтому улучшение относительно baseline не означает, что прогноз можно использовать без дополнительной экспертной проверки.

Практическая ценность модели заключается не в том, чтобы полностью заменить оценку команды, а в том, чтобы сделать процесс планирования более проверяемым. Например, если прогноз модели заметно отличается от оценки, поставленной вручную, это может быть сигналом для повторного анализа задачи: уточнения требований, проверки story points, пересмотра приоритета или анализа тегов. Такой подход особенно полезен для выявления потенциально рискованных задач, по которым модель ожидает более длительное выполнение, чем было запланировано изначально.

Важно учитывать и область применения построенной модели. Она была обучена на типовых задачах со сроком выполнения до 45 дней. Более длительные задачи были исключены из обучающей выборки, так как их продолжительность может быть связана не только с реальной трудоемкостью, но и с организационными задержками, блокировками, ожиданием согласований или несвоевременным закрытием задачи в системе. Поэтому модель корректнее применять к задачам, похожим на те, которые использовались при обучении. Для нестандартных и длительных задач ее прогноз может быть менее надежным.

Анализ ошибок показал, что качество прогноза различается для разных групп задач. Более высокие ошибки наблюдаются у задач с большими значениями story_points, а также у отдельных групп по типу и приоритету. Это означает, что сложные задачи труднее описать только теми признаками, которые доступны в текущем датасете. Вероятно, для них существенную роль играют дополнительные факторы: кто выполняет задачу, в каком проекте она находится, есть ли зависимости от других задач, возникают ли блокировки и насколько активно задача обсуждается в процессе выполнения.

Для дальнейшего улучшения качества модели целесообразно расширить набор признаков. В частности, полезно добавить информацию об исполнителе, команде, проекте, спринте, количестве комментариев, изменениях статусов, блокировках, переоткрытиях задач и зависимостях между задачами. Эти признаки могут лучше отражать не только исходную сложность задачи, но и процесс ее выполнения. Кроме того, для более строгой проверки качества в дальнейшем можно использовать временное разбиение данных: обучать модель на более ранних задачах и проверять ее на более поздних. Такой вариант ближе к реальному сценарию применения, когда модель строит прогноз для будущих задач на основе уже накопленной истории.

Итоговый результат показывает, что разработанная модель может быть полезна для прогнозирования сроков выполнения задач, но ее следует использовать с учетом ограничений исходных данных. HistGradientBoostingRegressor улучшил качество прогноза по MAE относительно baseline, однако средняя ошибка около 7 дней остается заметной для практического планирования. Поэтому наиболее корректный вариант применения модели - использовать ее вместе с экспертной оценкой команды: как инструмент проверки ETA, поиска рискованных задач и анализа причин отклонений в планировании.